

第八届 AIC 算法创新赛 · 赛题 2「AI+软件创新」

VeriFlow

VeriFlow 软件功能测试报告

自动化测试、合成变异基准、消融与未运行项的验收记录

赛题：第八届 AIC 算法创新赛 · 赛题 2「AI+软件创新」

文档类型：测试报告

技术架构：Next.js + FastAPI + Python 验证器 + Docker 沙箱

编制日期：2026 年 09 月

目录

- 一、测试目标与范围 3
 - （一）测试目标 3
 - （二）测试范围 3
- 二、自动化测试结果 3
 - （一）命令与结果 3
 - （二）用例锁住的算法性质 3
- 三、竞赛基准 4
 - （一）如何复现 4
 - （二）计分如何落到这 55 组 4
 - （三）被拒绝的 7 条补丁 5
- 四、消融与大模型对照 5
 - （一）同一套案例的四行 5
 - （二）全套结果和静态切片 6
- 五、案例与判题抽检 6
- 六、公网与版本 6
- 七、剩余风险与结论 6
 - （一）剩余风险 6
 - （二）测试结论 7
- 八、附录 7
 - （一）附录 A：结果文件 7
 - （二）附录 B：缺陷分级 7

一、测试目标与范围

（一）测试目标

本轮记录两件事。一是文档编制当天重跑的后端自动化测试。二是已经写入仓库、并被公网基准页读取的竞赛基准。测试不新增功能，也不为了维持分数去改案例。

（二）测试范围

表 1-1 测试范围

类别	覆盖内容	本次口径
后端自动化	中间表示、验证、修复、沙箱、接口、基准约束	2026-09-30 重跑通过
竞赛基准	55 组检测、诊断、定位、修复与消融	采用 2026-09-19 的结果文件
大模型对照	仅需求与工作流，不含故障答案	状态为未运行
前端浏览器	浏览器规格位于 apps/web/tests	本次没有重跑
公网	8081 上的版本与基准页	2026-10-05 核对，见 /api/version

二、自动化测试结果

（一）命令与结果

在仓库根目录执行 `python -m pytest -q --tb=no`。2026-09-30 的结果是 287 passed，1 条依赖库弃用警告，耗时约 163 秒，进程退出码 0。警告来自 Starlette 对 httpx 的弃用提示。用例本身全部通过。

这一轮没有同时重跑 `tsc`、`npm run build` 和 `Playwright`。因此本报告不填写前端用例条数。前端规格仍在 `apps/web/tests`，包括证据工作台、图布局和可读性。

表 2-1 自动化命令

命令	本次结果	说明
<code>python -m pytest</code>	287 passed	2026-09-30，开发机 Python 3.14
<code>python scripts/competition_benchmark.py</code>	未在本次重跑	引用已入库的 <code>competition</code> 结果
前端生产构建与浏览器规格	本次未跑	不把旧次数写进本次结论

（二）用例锁住的算法性质

用例覆盖工作流与规格的合法和非法输入、静态规则的反例、缺少审题门不能放行、运行轨迹截断、受约束修复的接受和回滚、沙箱的编译错误、答案错误、超时和

通过、对拍不一致、暴力超时与选手答案错误的区分、教练在通过题上不可用、三角色接口，以及竞赛基准的方法学约束。

方法学约束包括：去掉安全维仍跑运行监视；模型载荷不含故障答案；运行时故障不计入静态修复分母；检测和诊断分开；干净底图先通过检查。增量测试比较总状态、问题码和失败约束，结论限于这些字段和测试输入。

三、竞赛基准

（一）如何复现

```
python scripts/competition_benchmark.py
python scripts/competition_benchmark.py --llm-repeats 3
```

第二行只有在环境里配置了评测密钥时才会真正调用模型。当前结果文件对应的是没有密钥的一次运行。结果目录是 experiments/runs/competition/。生成时间是 2026-09-19T07:02:56Z。数据集名称为 competition-v2。冒烟目录里的小样本只用于冒烟。主结果以竞赛目录为准。

（二）计分如何落到这 55 组

检测把「故障样本上出现异常」记为抓住，把「正常样本上出现异常」记为误报，再合成检测 F1。诊断要求静态问题码等于注入时期望的码，或运行失败文本含约定短语。定位要求问题的节点、边或见证路径碰到被改位置；运行时故障还要求失败项点到被截断的节点。修复接受率的分母排除 5 条运行时专有故障。

表 3-1 完整模式结果

指标	值	计数
正常流程	5	全部没有被误报
注入故障	50	全部被检测为异常
检测精确率 / 召回率 / 检测 F1	1.000 / 1.000 / 1.000	50 条故障都报了异常，5 条正常流程都没有误报
诊断正确率	1.000	50/50 对上约定目标
定位正确率	0.700	35/50 点到被改动位置
可修复案例	45	5 条运行时故障不进入分母
修复接受 / 拒绝	38 / 7	接受率 0.844
平均静态耗时	0.175 毫秒	进程内计时，不含网页等待
平均运行监视耗时	0.114 毫秒	完整模式每一组都跑了监视
增量加速	未测量	不填写倍数
大模型对照	未运行	评测密钥未设置

检测 F1 为 1，是因为精确率和召回率都是 1。定位仍是 0.700，修复接受率仍是 0.844。三个数字回答三件不同的事。控制台的平均静态核验按一位小数显示，0.175 毫秒在那一格是 0.2 ms。

（三）被拒绝的 7 条补丁

表中 missing_branch 表示缺了一条分支，broken_binding 表示节点之间的绑定被改坏。六条是补丁没有使结果变好，一条是补丁不合法。接受率按 38/45 计算。

表 3-2 修复拒绝明细

底图	故障	拒绝原因
merge_dual	missing_branch	补丁没有使结果变好
merge_dual	broken_binding	补丁没有使结果变好
dataflow_typed	missing_branch	补丁没有使结果变好
dataflow_typed	broken_binding	补丁没有使结果变好
safety_env	missing_branch	补丁没有使结果变好
branch_notify	missing_branch	补丁没有使结果变好
branch_notify	broken_binding	补丁不合法

四、消融与大模型对照

（一）同一套案例的四行

表 4-1 消融

运行方式	检测 F1	召回率	说明
只做结构	0.462	0.300	不跑语义、数据流、安全、可达，也不跑运行监视
去掉安全维	0.889	0.800	运行监视仍然开启
关闭运行监视	0.947	0.900	五个静态维都开，漏掉的是 5 条运行故障
完整	1.000	1.000	静态加运行监视

四行的精确率都是 1，5 条正常流程都没有被误报。分数差来自漏报。页面上这四行写成仅结构检查、关闭安全检查、仅静态验证、完整验证。基准页上的确定性静态验证等于仅静态验证，也就是关掉运行监视。完整验证是 1.000。

（二）全套结果和静态切片

llm_judge.json 里有一份静态切片：去掉 5 条运行时故障后，剩下 45 条故障加 5 条正常流程，静态检测 F1 是 1。这份切片用来给模型对照作参照，模型本身没有运行。全部 55 组在关闭运行监视时，仍是表 4-1 的 0.947。

大模型对照的状态字段是 NOT RUN，原因是 DEEPSEEK_API_KEY 未设置，重复次数为 0，分数字段为空。提示词版本记录为 competition-llm-judge-v3-static。文件注明这条对照永远不作为门禁。

五、案例与判题抽检

表 5-1 案例事实抽检

案例	期望	依据
生成器直接入库	缺审题门和上界守卫，直连入库	case1_order.json
object 对 string	生成器与范围守卫类型不一致	case2_dataflow.json
明文 api_key	审题门仍在，问题是硬编码密钥	case3_safety.json
支付分支后截断	静态可通过，门禁拦截，通知、审题门与入库未执行	case4_runtime.json

选手侧的样例通过、隐藏数据失败、反例来源和 Python 参考解变异，可由 python scripts/eval.py 复现，输出在 artifacts/eval.json。该脚本只覆盖做题路径。55 组出题基准以上面的结果文件为准。本次编制文档没有重跑 eval.py。

六、公网与版本

2026-10-05 核对公网演示。当前版本以 /api/version 返回的 git_commit 和 built_at 为准；2026-09-30 的 eb94cec30307 及构建时间仅为历史发布记录。

87257ea815784e05f36f62b7293a0b8629d103ae
eb94cec30307dfcf24b45ee470c8acd617a23f7f

七、剩余风险与结论

（一）剩余风险

特殊评判、交互题、Java 尚未实现。C++ 语法树变异尚未实现，参考解变异打在 Python 上。真实 n8n 和 Dify 尚未接入。增量加速尚未测量。大模型对照尚未运行。安全检查和证据包提供可复核记录，不构成形式化证明。

公网构建若把内存上限压到 1G，Next 构建可能被系统杀掉。发布步骤必须在独立目录构建，并在接口健康之后再切换前端。细节见部署文档。

(二) 测试结论

后端自动化测试在 2026-09-30 通过，共 287 项。竞赛基准的完整模式抓住了全部 50 条注入故障，5 条正常流程没有被误报。定位正确率 0.700。静态修复接受 38 条、拒绝 7 条。只做结构或关掉运行监视都会漏报。大模型没有参加打分。未运行的项目在结果文件和页面上保持空白。

八、附录

(一) 附录 A：结果文件

表 8-1 结果文件

文件	作用
experiments/runs/competition/metrics.json	主指标与 7 条拒绝
experiments/runs/competition/ablation.json	四行消融
experiments/runs/competition/llm_judge.json	未运行状态与静态切片参考
experiments/runs/competition/cases.csv	逐条案例
experiments/runs/competition/README.md	复现命令与口径

(二) 附录 B：缺陷分级

缺陷按阻断、严重、一般和建议分级。主路径打不开、把未运行写成分数、案例与源文件不一致属于阻断；统计口径错误属于严重。关闭记录以对应版本和测试证据为准。