

第八届 AIC 算法创新赛 · 赛题 2「AI+软件创新」

VeriFlow

VeriFlow 软件功能需求分析文档

面向大模型出题工作流的规格验证、门禁与算法训练判题

赛题：第八届 AIC 算法创新赛 · 赛题 2「AI+软件创新」

文档类型：需求分析

技术架构：Next.js + FastAPI + Python 验证器 + Docker 沙箱

编制日期：2026 年 09 月

目录

- 一、赛题背景与业务目标 3
 - （一）业务痛点 3
 - （二）建设目标 3
- 二、用户角色与典型场景 3
 - （一）角色边界 3
 - （二）两条主路径 4
- 三、功能需求 4
 - （一）控制台 4
 - （二）出题质检 4
 - （三）沙箱判题、对拍与题库 5
 - （四）评测基准 5
 - （五）证据导出与其余入口 5
 - （六）管理 6
- 四、核心算法需求 6
- 五、非功能需求与运行约束 7
 - （一）可用性 7
 - （二）部署与安全 7
- 六、需求追踪与验收标准 7
 - （一）优先级 7
 - （二）验收口径 8
- 七、数据质量与边界场景 8
 - （一）基准数据的质量要求 8
 - （二）异常和边界 8
- 八、用户故事与验收用例 9
- 九、附录 9
 - （一）附录 A：赛题能力映射 9
 - （二）附录 B：术语 9

一、赛题背景与业务目标

（一）业务痛点

大模型已经能根据一段题意生成出题流程图，也能起草选手代码。这些输出本身还不能当作判定。只看公开样例时，隐藏数据上会失败的程序也会被判成通过。出题图可能缺审题门、把类型接错，或把密钥写进节点配置。运行轨迹也可能在图仍然完整时提前断开。若再让同一个模型给自己打分，结论不稳定，也没有可复核的证据。

VeriFlow 补上的就是判定这一段：模型可以提案，检查器负责否决。出题流程先变成带类型的工作流，再经过静态检查、运行轨迹和门禁，通过之后才入库。选手代码由沙箱执行，对错以沙箱结果为准。

（二）建设目标

给评委和出题人一个可点击的 Web 工作台。顶栏依次能进入控制台、题库训练、沙箱判题、智能对拍、出题质检和需求出题。

把「检测是否抓到故障」「诊断是否对上故障类型」「定位是否指到被改动的位置」「补丁是否被重新检查接受」分成四件不同的事，并在同一套基准上给出可复现数字。四件事依次更具体：抓住异常，不等于报对了故障码；报对了故障码，不等于点到了被改的节点；点到了节点，也不等于补丁会被接受。

保留算法训练站能力：30 道自写题，编号 VF1001 至 VF1030，判定包含编译错误、答案错误、超时、内存超限、运行错误和通过。答案错误时给出输入、期望、实际三列。判定来自沙箱。

公网演示使用 8081 端口。80 端口留给主机默认站点。需求结论是：VeriFlow 把出题和判题收成可导出的证据，内容包括约束、轨迹和沙箱结果。

二、用户角色与典型场景

（一）角色边界

系统预置三类账号。下面的口令只用于公网演示。菜单里隐藏某个入口，接口仍会按角色校验。

表 2-1 用户角色与主要职责

角色	演示账号	主要任务
选手	demo / demo	看题、提交、看反例、对拍

出题	setter / setter	编写需求、检查出题图、受约束修复
管理员	admin / admin	用户与题目发布等管理操作

（二）两条主路径

出题路径：需求或示例图进入工作流中间表示。中间表示是出题图的规范形式，包含节点、边、类型和配置。静态检查和运行监视给出问题与证据，受约束修复可以提出补丁，门禁决定能否放行。模型可以参与把题意编成图。最终放行由门禁决定。

做题路径：选手提交 C++17 或 Python3。沙箱先跑公开样例和隐藏数据，错了给出输入、期望、实际。对拍用生成器和暴力解，停在第一组对不上的数据。教练只在已有反例时追问，不直接贴出完整题解。普通提交不因为交了一次代码就调用大模型。

三、功能需求

（一）控制台

选手和出题人登录后进入控制台，管理员进入账号页。控制台标题下方展示同一套合成变异基准的三项：检测 F1、静态修复接受率、平均静态核验。数字来自接口。

检测 F1 是 0 到 1 的分数，同时看两件事：故意放进去的故障要被抓住，正常流程保持通过。静态修复接受率表示适用静态故障中，有多少在修复结束后达到静态通过。平均静态核验是这套基准里静态检查的平均耗时，统计的是进程内检查，不含打开网页的等待时间。这三项的标签直接显示在标题下方。含义见本文件术语表和产品说明书。

（二）出题质检

出题质检页先在「核验案例」里选定一条，再点「运行案例」，图和问题列表才会换成这一条。只改下拉时，故事板文字会先变，图和问题列表仍停在上一一条。四条案例的事实以点过「运行案例」、画面停稳之后为准。

表 3-1 四条核验案例

下拉名称	必须成立的事实
缺少审题门 · 生成器直接入库	图为生成器指向入库。缺审题门与上界守卫，并有规格动作未满足。补审题门。
类型不一致 · object 对 string	生成器输出 object，下一跳范围守卫输入 string。检查结果是 gen:object 到 g_bounds:string

明文密钥·生成器配置写死 <code>api_key</code>	审题门还在图上。生成器配置里的 <code>api_key</code> 是明文，检查报硬编码密钥
静态全绿·动态沙箱断流 (典型案例)	静态可以通过，审题门仍在图上。分支条件是 <code>payment_status</code> 等于 <code>success</code> 。轨迹在支付状态分支之后终止，通知、审题门和入库都没有被执行，因此被门禁拦截

（三）沙箱判题、对拍与题库

沙箱判题列表可以打开一条已经判完的错误提交，详情里能看到输入、期望、实际三列。对拍由环境执行生成器和暴力解。暴力解超时记为对拍错误，与选手答案错误分开记录。

题库可按题号浏览。自写题 30 道。竞赛题单里的「签到时长」是 VF1001，「括号匹配」是 VF1004。语言是 C++17 和 Python3。

（四）评测基准

评测基准页展示仓库内合成变异套件的结果，并写明范围限于这套案例。页首能看到用例总数和检测 F1，说明文字里写着大模型对照的状态。没有评测密钥时，这一状态是未运行，页面不填写分数。同一套 0.844 在这一页记在对照表的「修复率」，以及后面「修复」一段的「成功率」。控制台标题下才使用「静态修复接受率」这个标签。

只做结构检查、去掉安全维、关掉运行监视这三组对照，与完整结果来自同一次运行、同一批案例。关掉运行监视的检测 F1 必须和完整结果区分开。前者在这套数据上是 0.947，后者是 1.000。

（五）证据导出与其余入口

证据链分析可以导出 JSON 和 Markdown。导出包包含 workflow 哈希、运行编号、时间、来源需求、规格、静态问题与见证、运行状态与轨迹、门禁、修复记录和模型调用痕迹。包内声明该文件不是形式化证明。密钥不进入导出文件。

验证实验室里还需要算法矩阵、系统架构和历史记录。算法矩阵必须列出真实实现的算法标识、复杂度和代码位置，不能只放介绍卡片。需求出题页可以打开残缺示例并做受约束修复。修复没有变得更好时，补丁被拒绝，图保持原样。

（六）管理

管理员可以查看用户、调整账号状态，并处理题目发布。

不能停用自己，也不能停用最后一个仍可用的管理员。

四、核心算法需求

算法全部在仓库内实现，可以在没有大模型密钥时完成判定。下表是需求层对能力的约定。设计文档给出每一种算法的步骤、复杂度和优化取舍。验收时既看页面，也看对应测试是否把这些约定锁住。

表 4-1 核心算法需求

能力	必须满足的性质	预期输出
规格编译	默认路径不调用模型，输出可检查约束	workflow 规格
静态多维验证	结构、语义、数据流、可达、安全分开记状态；未知不把总状态记成通过	通过、失败、警告或尚未能判定
可达性见证	能给出一条避开强制检查点的路径，不枚举全部路径	见证路径
时序监视	一次扫描判定约定的规则子集；观察不到的分支记为未知	轨迹符合性
轨迹对齐	并发对调不报乱序；违反偏序才记乱序	对齐行与偏离
增量验证	局部改动可缩小重跑范围；拓扑大改退回全量，并与全量结果一致	验证结果与是否回退
受约束修复	非法补丁不落地；接受前必须全量验证变好；拒绝时保留原图	接受或拒绝
可靠性门禁	读静态、运行和策略；模型不进入	放行、待复核或拦截
合成变异评测	故障按清单枚举；检测、诊断、定位、修复分开计分	可复现的四项数字
沙箱判定	隐藏数据与公开样例分开；错误时带最小反例	编译错误至通过
对拍	暴力超时与选手答案错误分开	第一组不一致的数据

检测、诊断、定位、修复接受率分开计算。大模型对照若要运行，输入只能包含需求和完整 workflow，不能包含故障名、期望码、被改节点、截断点或提示。没有密钥时状态必须是未运行，不能填 0 分或满分来占位。

修复的优化需求是：每轮候选有上限，先用代价更低的筛选丢掉没有希望的补丁，再做全量验证；多份都通过时偏好改动更小的补丁。加速倍数没有测量值时，文档和页面写未测量，不推断一个倍数。

五、非功能需求与运行约束

（一）可用性

界面用中文业务词。协议里的 PASS、FAIL、READY 保留英文。检测 F1、静态修复接受率第一次在文档里出现时，用一句话写明含义。控制台标题下使用这两个中文标签。页面要能在桌面宽度完成演示。空列表、检查失败、门禁拦截都给出可读状态。

（二）部署与安全

参赛演示入口是 `http://116.62.5.67:8081/`。80 端口留给主机默认站点。大模型密钥只放在服务器环境变量里，不进前端，不进 git。没有密钥时，出题编译、起草和教练走本地回退，核心判定仍由验证器和沙箱完成。证据导出和日志不得带出密钥。

表 5-1 非功能指标

类别	指标	说明
可访问	8081 可登录并走通主路径	80 端口保持主机默认站点
可复现	基准命令可重跑	数字以仓库内结果文件为准，禁止手填满分
可区分	未运行和失败分开	没有密钥时大模型对照是未运行
可回退	前端按提交号发布	构建失败不切换正在服务的目录
可解释	问题带见证路径	证据包声明该文件不是形式化证明
可确定	同一输入得到同一判定	门禁不读取模型采样结果

六、需求追踪与验收标准

（一）优先级

P0 是评委五分钟内能走通的路径：登录、控制台口径、两条出题案例、一条沙箱反例、评测基准页上的未运行状态，以及 8081 部署。P1 包括证据导出、受约束修复、对拍、管理后台和另外两条核验案例。P2 包括特殊评判、交互题、Java、C++ 语法树变异、真实 n8n 连接和增量加速测量。P2 各项在文档中标明尚未实现或尚未测量。

表 6-1 需求追踪矩阵

编号	需求	设计落点	验收方式
R-01	模型提案、检查器否决	验证管线与门禁	案例页与门禁状态
R-02	缺审题门在入库前拦住	案例 1 与可达性见证	出题质检点运行案例

R-03	类型接错可指出两端	数据流	案例 2 文案
R-04	密钥和缺审题门分开记	安全策略	案例 3 文案
R-05	静态通过仍可因轨迹拦截	时序监视	案例 4 与门禁
R-06	错答能看到三列反例	沙箱判题	打开一条已有错误提交
R-07	数字可复现并标出未运行	评测基准页与结果文件	对照 metrics.json
R-08	修复可以被拒绝	受约束修复环	45 条里的拒绝记录
R-09	证据可导出且标明非证明	证据导出	JSON 字段检查
R-10	30 道自写题可提交	题库与沙箱	健康检查与样例提交
R-11	三角色隔离	登录与管理接口	接口测试
R-12	8081 部署，80 端口保持主机默认站点	nginx 与 systemd	公网地址与版本接口
R-13	增量验证与全量等价	影响集算法	等价测试
R-14	四项指标不混用	计分函数	基准页与测试报告

（二）验收口径

冻结验收看四件事：打得开、点得通、口径和页面一致、数字能复现。页面故事和基准文件冲突时，以基准文件和案例源文件为准，并修改页面。验收时核对结果文件，不改案例去维持分数。

七、数据质量与边界场景

（一）基准数据的质量要求

竞赛基准使用仓库内的合成变异，范围就是这 55 组。5 条底图在注入故障之前，静态检查必须通过，运行监视也必须通过。故障由确定的枚举生成。种子 20260919 只标记这批结果来自哪一次运行，不参与抽样。

有些故障要等运行才出现，例如在某个节点后截断轨迹，或强行走某一分支。这 5 条检查的是监视器，不进入静态修复的分母。

（二）异常和边界

没有大模型密钥时，大模型对照记为未运行，出题编译走回退，门禁照常工作。正常流程被报成故障时，检测 F1 把这种情况算进误报，不只统计抓住了多少故障。补丁没有变得更好，或补丁本身不合法，记为拒绝，接受率下降，页面列出原因。

只做结构检查会漏掉大量故障。消融表必须列出这个差距，避免把结构规则的通过说成完整验证。 $n8n$ 只做节点和连线的子集往返。没有凭证时不连接真实 $n8n$ ，走模拟运行。Dify 未实现。

八、用户故事与验收用例

表 8-1 核心用户故事

编号	作为	我希望	以便
US-01	评委	打开控制台就看见口径和数字	不用先听缩写
US-02	出题人	缺审题门时入库被拦住	空测资不会先发给学生
US-03	出题人	图还在、轨迹断了时仍然拦截	节点画在图上不等于已经执行
US-04	选手	做错时看到输入、期望、实际	知道改哪一组数据
US-05	评委	在评测基准页看到未运行	不会把没跑的模型对照当成成绩
US-06	管理员	用单独账号管理用户和发布	演示账号权限边界清楚

表 8-2 验收用例分组

分组	代表操作	失败时应表现
登录	使用 demo 进入控制台	口令错误有提示，不进入工作台
出题质检	选中后点运行案例	图和门禁与该案例事实一致
沙箱	打开一条已有错误提交	三列反例可见
基准	打开评测基准	页首有总组数、检测 F1、未运行；对照表有修复率
证据	导出 JSON	含哈希与非证明声明，不含密钥
部署	访问 8081 的健康检查	80 端口仍是主机默认站点

九、附录

（一）附录 A：赛题能力映射

创新性落在角色隔离、多维验证、运行轨迹和可以拒绝的修复。技术实现落在自研工作流中间表示、确定性验证器、门禁和沙箱。功能完整性落在题库、提交、对拍、出题质检、基准和证据导出。应用价值落在两处：只看公开样例会漏掉的错误，由沙箱在隐藏数据上抓住；大模型画出的出题图，在入库前被拦住。

（二）附录 B：术语

检测 F1：把「故障都被抓住」和「正常流程没有被误报」合成一个 0 到 1 的分数。两项都满分时它才是 1。它只描述这一套 55 组案例。

诊断正确率：故障案例里，报出的问题码或运行时文本与注入时约定的目标一致的比例。

定位正确率：问题列表的节点、边或见证路径碰到了被改动位置的比例。

静态修复接受率：适用的静态故障经修复结束后达到静态 PASS 的比例，为 38/45。中间候选被接受与最终静态通过分开记录，运行时专有故障排除。

门禁：根据静态结果、运行结果、严重级、未知项和覆盖率下限决定放行、待复核或拦截。模型不进入这一步。退出码 0 可以是放行，也可以是待复核。退出码 1 是拦截。退出码 2 是命令行工具错误，不是门禁判定。

工作流中间表示：出题图的规范形式，包含节点、边、类型和配置。后文与设计文档中的 WorkflowIR 指同一对象。

合成变异：在仓库里的正确底图上按清单改坏，再让验证器去抓。它自带标准答案，用来算分。结果只对这批案例有效。

尚未能判定：这一项现在下不了结论。验证总状态因此不记成通过。默认策略下，运行监视的尚未能判定只记警告，不单独拦截。安全类的尚未能判定可以拦截。当前安全检查写出的是失败，不是尚未能判定。